Propuesta Proyecto Final

Inteligencia Artificial Probabilística

Máster Universitario en Inteligencia Artificial · Universidad Pontificia Comillas · 2025/2026

Título: Detección de Fraude Bancario mediante Redes Neuronales Bayesianas con Inferencia Variacional

Alumno: *Antonio Lorenzo Díaz-Meco - Francisco Javier Ríos Montes*

Dataset: Credit Card Fraud Detection (Kaggle) — 284.807 transacciones reales, 0,172 % fraude (TBD)

Problema y motivación

La detección de fraude en transacciones con tarjeta de crédito constituye un problema de clasificación binaria con desafíos probabilísticos inherentes: desbalanceo extremo de clases (1:578), ruido en las features y patrones de fraude en constante evolución. Los modelos deterministas clásicos producen estimaciones puntuales que impiden cuantificar la confianza de cada predicción, lo que limita su utilidad operativa en entornos donde las decisiones erróneas tienen costes asimétricos.

Ahí es donde la aplicación de redes neuronales bayesianas (BNN) como las que hemos ido estudiando a lo largo del semestre puede ser extremadamente útil: emitiendo una distribución predictiva completa $p(y \mid \mathbf{x})$ en lugar de una etiqueta puntual (con las desventajas de MLE que veíamos). La incertidumbre cuantificada se traduce directamente en valor de negocio: una transacción con alta incertidumbre *epistémica* se deriva a revisión humana, reduciendo tanto falsos positivos como pérdidas por fraude no detectado.

Aproximación probabilística

El modelo aprende una distribución posterior sobre los pesos $p(\mathbf{W} \mid \mathcal{D})$, intratable en forma exacta. La inferencia se realiza mediante **inferencia variacional** (VI), aproximando el posterior con una familia gaussiana $q(\mathbf{W}; \boldsymbol{\phi})$ y maximizando la cota inferior de la evidencia (ELBO):

$$\mathcal{L}(\boldsymbol{\phi}) = \mathbb{E}_q\big[\log p(\mathcal{D} \mid \mathbf{W})\big] - \mathrm{KL}\big[q(\mathbf{W}; \boldsymbol{\phi}) \,\|\, p(\mathbf{W})\big] \tag{1}$$

El prior $p(\mathbf{W}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ se justifica por la estandarización previa de las features. El desbalanceo de clases se incorpora como conocimiento experto en el prior del sesgo de la capa de salida [1], regularizando así el modelo inicial hacia la distribución real de clases.

La incertidumbre total sobre cada predicción se descompone en sus componentes *aleatoria* (irreducible, ruido en los datos) y *epistémica* (reducible, desconocimiento del modelo), estimadas mediante muestreo Monte Carlo del posterior aproximado.

[1] $b_0 = \log(0{,}0017/0{,}9983)$

Dataset y deficiencias realistas

El dataset (si finalmente usamos el de Kaggle) contiene 29 features: 28 componentes PCA anonimizadas ($V_1, \ldots, V_{28}$), el importe (`Amount`) y la marca temporal (`Time`). Se introducirán artificialmente datos faltantes en `Amount` y `Time` para demostrar la robustez del enfoque bayesiano frente a modelos deterministas de referencia.

Métricas y valor de negocio

Las métricas a usar para evaluar el modelo deben ser seleccionadas todavía, pero se priorizarán aquellas que reflejen tanto la calidad de las probabilidades predichas (NLL, ECE) como su impacto en la operación real (tasa de derivación a revisión), unas para evaluar la calibración y capacidad discriminativa *offline* y otras para medir el impacto a nivel operativo *online*.

Se desarrollará una demo interactiva en **Streamlit** que permita visualizar $p(\text{fraude} \mid \mathbf{x})$ junto con las bandas de incertidumbre y el umbral de decisión ajustable en tiempo real.

Stack tecnológico

PyMC para el modelo bayesiano base; **torch** para escalado con SVI sobre minibatches; **Streamlit** para la demo interactiva; **MLflow** para seguimiento de experimentos; **Docker** para reproducibilidad del entorno.